

Clasificación Multimodal para la Predicción de Adopción

Comparativa de Arquitecturas: Baselines vs. Modelos Híbridos

Álvaro Lorenzo Marcos Ortiz Alberto Águila

3 de febrero de 2026

Objetivo y Enfoque del Proyecto

- **Problema:** Predecir la velocidad de adopción de mascotas basándose en datos heterogéneos.
- **Desafío:** Combinar información visual (imágenes) y tabular (metadatos) haciendo uso de modelos híbridos.
- **Enfoque:** Comparativa de distintas estrategias:
 - 1 Establecer Modelos Base Unimodales
 - 2 Tratar el problema como clasificación
 - 3 Tratar el problema como regresión


Velocidad: 1



Velocidad: 2



Velocidad: 1



Velocidad: 3



Velocidad: 2




Análisis Exploratorio de Datos (EDA) y Preprocesamiento

- 1 Análisis Exploratorio de Datos (EDA) y Preprocesamiento
- 2 Bloque A: Modelos Unimodales (Baselines)
- 3 Bloque B: Modelos Híbridos
- 4 Bloque C: De Clasificación a Regresión
- 5 Resultados y discusión
- 6 Conclusiones

Análisis Exploratorio de Datos (EDA)

- **Variable Objetivo:** AdoptionSpeed (Clases 0-4).
- **Desbalanceo de Clases:** Infrarepresentación de la clase 0, lo que justifica el uso de **Quadratic Weight Kappa (QWK)** sobre Accuracy. Para solucionar esto, penalizaremos más los fallos en la clase cero calculando pesos inversamente proporcionales a la frecuencia de dicha clase en nuestro dataset



Preprocesamiento de los Datos

Dividimos el preprocesamiento para datos tabulares / imágenes:

- **Datos Tabulares:**

- Imputación de nulos.
- *Label Encoding* para variables categóricas y *Standard Scaling* para variables numéricas.
- Se probó la transformación de descripciones mediante **TF-IDF** para ver si mejoraba el rendimiento.

- **Datos Visuales (Imágenes):**

- Reescalado a 256×256 y recorte central/aleatorio a 224×224 .
- *Data Augmentation* (para train): Flips horizontales y Color Jitter para evitar sobreajuste.
- Normalización: Ajuste según medias y desviaciones de ImageNet (CNN con pesos de ImageNet).

Bloque A: Modelos Unimodales (Baselines)

- 1 Análisis Exploratorio de Datos (EDA) y Preprocesamiento
- 2 Bloque A: Modelos Unimodales (Baselines)**
- 3 Bloque B: Modelos Híbridos
- 4 Bloque C: De Clasificación a Regresión
- 5 Resultados y discusión
- 6 Conclusiones

Bloque A: Modelos Unimodales (Baselines)

- **Objetivo:** Establecer una línea base de rendimiento para cada modalidad de datos por separado para posteriormente ver si los modelos híbridos, más complejos, lo mejoran.
- **Justificación:** Cuantificar el valor predictivo de la imagen frente a los metadatos.

Rama Tabular

- Datos: Metadatos estructurados (Edad, Raza, Salud...).
- Técnica: Random Forest
- **QWK: 0.330 (sin Descripción) / 0.299 (con Descripción)**

Rama Visual: EfficientNet-B0

- Datos: Fotografía principal (224x224).
- Técnica: Transfer Learning.
- **QWK: 0.256**

Análisis de la Capacidad Predictiva (Bloque A)

- **Dominancia Tabular:** El modelo de datos tabulares supera a la imagen por un margen significativo ($+0,074$ QWK).
- **Procesado de descripción:** Agregar la descripción mediante TF-IDF no mejora el rendimiento ($-0,031$ QWK) y solo introduce ruido.
- **Limitaciones Visuales:**
 - La estética de la foto es subjetiva y no siempre correlaciona con la velocidad de adopción.
 - Ruido visual: Fondos distractores o fotos de baja calidad.
- **Conclusión:** La información estructurada es el predictor principal, pero la imagen aporta matices necesarios para discriminar clases extremas.

Esto justifica la transición al **Bloque B: Modelos Híbridos** para buscar sinergias.

Comparativa de Errores: Tabular vs. Visual

Random Forest (Tabular)




Figura: Mayor precisión en clases mayoritarias

CNN EfficientNet (Visual)




Figura: Capacidad de detección en Clase 0

Bloque B: Modelos Híbridos

- 1 Análisis Exploratorio de Datos (EDA) y Preprocesamiento
- 2 Bloque A: Modelos Unimodales (Baselines)
- 3 Bloque B: Modelos Híbridos**
- 4 Bloque C: De Clasificación a Regresión
- 5 Resultados y discusión
- 6 Conclusiones

Estrategia 1: Fusión Temprana (Early Fusion)

Concepto


Concatenación de los vectores de características de ambas modalidades *antes* de entrar al modelo clasificador principal.

$$V_{fusión} = [V_{tabular}, V_{CNN_features}]$$

Resultado: QWK 0.222 (Bajo)

- **Dimensionalidad:** El vector visual es enorme y ruidoso comparado con el tabular.
- **Contaminación:** El RF pierde capacidad de hacer cortes limpios en variables críticas.

Arquitectura de Fusión Temprana (Early Fusion)



Estrategia 2: Fusión Tardía (Late Fusion)

Concepto: Ensembles


Entrenamiento independiente de cada rama (Tabular y Visual). La fusión ocurre al final promediando las probabilidades (*Soft Voting*).

$$P_{final} = \alpha P_{Tab} + (1 - \alpha) P_{Vis}$$

Resultado: QWK 0.365

- **Independencia:** El ruido de la imagen no contamina el aprendizaje del árbol de decisión.
- **Sinergia:** Los errores están descorrelacionados; la tabla aporta solidez y la imagen matices.

Arquitectura de Fusión Tardía (Ensamble)



Matriz de Confusión: Fusión: CNN + RF

Clase Real	0	1	2	3	4
	0	38	20	5	24
	1	0	215	217	50
	2	0	160	315	97
	3	0	99	165	131
4	0	61	126	46	551
	0	1	2	3	4

Estrategia 3: Modulación Lineal (FiLM)

Resultado: QWK 0.319

Mejora vs CNN (+0,063):


- La inyección de metadatos ayuda a la red a enfocar su atención.
- Se validan las hipótesis de los parámetros γ y β .

Limitación Estructural

Sesgo Visión-Céntrico:

- El modelo sigue dependiendo del flujo visual (que es más débil).
- Al subordinar la tabla a la imagen, no alcanza la robustez del RF puro.

Arquitectura de Modulación Lineal (FiLM) - Detallada



Bloque C: De Clasificación a Regresión

- 1 Análisis Exploratorio de Datos (EDA) y Preprocesamiento
- 2 Bloque A: Modelos Unimodales (Baselines)
- 3 Bloque B: Modelos Híbridos
- 4 Bloque C: De Clasificación a Regresión**
- 5 Resultados y discusión
- 6 Conclusiones

Reformulación del Problema: De Clasificación a Regresión

Justificación del Enfoque

Aunque las etiquetas son discretas (0 – 4), existe una **relación ordinal intrínseca**:

$$0 \text{ (Muy rápida)} \approx 1 \text{ (Rápida)} \neq 4 \text{ (Nula)}$$


Limitación de Clasificación

- Trata las clases como independientes.
- Penaliza igual un error pequeño ($0 \rightarrow 1$) que uno grave ($0 \rightarrow 4$).

Ventaja de la Regresión

- Captura la **magnitud del error**.
- Se alinea matemáticamente con la métrica **QWK** (penalización cuadrática).
- Aprende la continuidad de la adoptabilidad.

Optimización de Cortes (Thresholds) - Fusión CNN + RF (Validación)




Impacto del Cambio de Paradigma: Clasificación vs. Regresión

El Boost de la Regresión

Capturar la ordinalidad ($0 \approx 1 \neq 4$) dispara el rendimiento:

- **Fusión Temprana (+17.6 %):**
Aunque el salto porcentual es alto, parte de una base muy pobre.
- **FiLM (+4.7 %):**
La mejora es leve.
- **Fusión Tardía (+10.4 %):**
Mejorar un 10 % sobre un modelo que ya era bueno (0.365) es muy difícil. Esto confirma que la regresión era la pieza que faltaba para romper el techo de cristal.



Resultados y discusión

- 1 Análisis Exploratorio de Datos (EDA) y Preprocesamiento
- 2 Bloque A: Modelos Unimodales (Baselines)
- 3 Bloque B: Modelos Híbridos
- 4 Bloque C: De Clasificación a Regresión
- 5 Resultados y discusión
- 6 Conclusiones

Resumen Global de Resultados

Modelo / Arquitectura	QWK	Coste Comp.
<i>Baselines Unimodales</i>		
Random Forest (Tabular)	0.330	Bajo
CNN EfficientNet (Visual)	0.256	Alto
<i>Híbridos - Enfoque Clasificación</i>		
Fusión Temprana	0.222	Bajo-Medio
FiLM	0.319	Alto
Fusión Tardía	0.365	Alto
<i>Híbridos - Enfoque Regresión</i>		
Fusión Temprana	0.261	Medio-Alto
FiLM	0.334	Medio-Alto
Fusión Tardía	0.403	Alto

Conclusiones Clave

- **Mejor Modelo:** Fusión Tardía con Regresión (+22 % vs Baseline).
- **Trade-off:** El ganador tiene un coste computacional alto (requiere entrenar 2 modelos), pero la mejora en QWK lo justifica para producción.
- **Regresión frente Clasificación:** El cambio de paradigma mejoro el QWK en todos los aspectos.

Discusión de Resultados: Análisis de Arquitecturas

1. Fusión Temprana

Rendimiento: Bajo

- **Diagnóstico:** La concatenación introduce ruido dimensional.
- **Causa:** Los vectores visuales son complejos y de alta varianza, diluyendo la señal limpia de los metadatos. El Ramdon Forest pierde eficacia en los cortes.

2. FiLM (Deep Learning)

Rendimiento: Prometedor

- **Acierto:** Supera a la CNN sola; la tabla enfoca a la visión.
- **Limitación:** Arquitectura *Visión-Céntrica*. Al ser la tabla el predictor fuerte, subordinarla a la imagen limita el potencial.

3. Fusión Tardía

Rendimiento: Óptimo

- **Sinergia:** Especialización sin interferencias.
- **Descorrelación:** Los errores son distintos. Donde la imagen duda, la tabla decide (y viceversa).

Conclusiones

- 1 Análisis Exploratorio de Datos (EDA) y Preprocesamiento
- 2 Bloque A: Modelos Unimodales (Baselines)
- 3 Bloque B: Modelos Híbridos
- 4 Bloque C: De Clasificación a Regresión
- 5 Resultados y discusión
- 6 Conclusiones**

El Factor Diferencial: Enfoque de Regresión

Más allá de la arquitectura, tratar el problema como **Regresión** fue decisivo:

- Se alinea matemáticamente con la métrica QWK (penalización cuadrática).
- Captura la naturaleza ordinal: *Adopción Muy Rápida (0) $\approx$ Rápida (1)*.

Lecciones Aprendidas:

- 1 **Dominancia Tabular:** En PetFinder, los metadatos (raza, edad...) pesan más que la estética.
- 2 **Valor de la Multimodalidad:** Aunque la tabla manda, la imagen aporta una mejora incremental valiosa para refinar casos límite.
- 3 **Estrategia Ganadora:** *Fusión tardía con Regresión*



Objetivo Cumplido

¡Muchas Gracias!

Clasificación Multimodal para la Predicción de Adopción