

Proyecto Integrado ML/DL: Predicción Multimodal de Adoptabilidad de Mascotas (Discusión Crítica de Resultados)

Comparativa de Modelos Unimodales frente a Arquitecturas Híbridas

Autores:

Álvaro Lorenzo Hidalgo

Marcos Ortíz Durán

Alberto Águila Prieto

Universidad Loyola

Sevilla, España

3 de febrero de 2026

Índice general

1	Introducción	2
1.1	Contexto	2
1.2	Objetivos del Trabajo	2
1.3	Modelos Unimodales	3
1.3.1	Datos Tabulares	3
1.3.2	Imágenes	4
1.4	Arquitecturas Multimodales: Enfoque de Clasificación	5
1.4.1	Fusión Temprana	5
1.4.2	Fusión Tardía	5
1.4.3	Modulación Lineal de Características (FiLM)	6
1.5	Arquitecturas Multimodales: Enfoque de Regresión	7
1.5.1	Fusión Temprana (Regresión)	7
1.5.2	Fusión Tardía (Regresión)	8
1.5.3	Modulación Lineal de Características (FiLM - Regresión)	8
2	Discusión y Conclusiones	8
2.1	Discusión Crítica de las Estrategias de Fusión	8
2.1.1	Ineficacia de la Fusión Temprana: El Problema del Ruido Dimensional . .	9
2.1.2	FiLM: Potencial y Limitaciones	9
2.1.3	Fusión Tardía: La Sinergia de Expertos Independientes	9
2.2	El Impacto del Cambio de Paradigma: Clasificación vs. Regresión	9
2.3	Conclusiones Generales	10
3	Anexo: Aprendizajes de la asignatura	11
3.1	Aprendizajes clave del trabajo	11
3.2	Aprendizajes adquiridos en la asignatura de Deep Learning	11
3.3	Aprendizajes adquiridos en la asignatura de Machine Learning	12

1 Introducción

1.1 Contexto

La predicción de la velocidad de adopción de animales domésticos representa uno de los desafíos más ilustrativos en la intersección actual entre el aprendizaje supervisado sobre datos tabulares y el análisis de contenido no estructurado mediante visión artificial. A diferencia de los problemas convencionales de clasificación, el conjunto de datos *PetFinder* exige la síntesis de dimensiones heterogéneas: por un lado, variables biológicas y administrativas (edad, raza, estado de salud, cuota de adopción) y, por otro, información visual Figura 1.1 que captura el atractivo estético y emocional de la mascota.



Figura 1.1. Visualización de las 5 primeras imágenes del conjunto de datos con su etiqueta asociada.

En este dominio, la integración de modelos de Machine Learning (ML) clásico y Deep Learning (DL) trasciende la mejora incremental para convertirse en una necesidad arquitectónica. El objetivo fundamental es resolver la disparidad en la densidad informativa de las distintas modalidades. Mientras que los datos tabulares se caracterizan por una alta señal predictiva y baja dimensionalidad, las imágenes poseen una alta dimensionalidad pero requieren procesos de optimización significativamente más complejos para extraer características latentes útiles.

1.2 Objetivos del Trabajo

El presente proyecto tiene como objetivo principal diseñar e implementar arquitecturas para la predicción sobre el conjunto de datos "PetFinder", evaluando progresivamente diferentes técnicas de fusión multimodal. La metodología de trabajo sigue un enfoque incremental: comienza con la evaluación exclusiva de datos tabulares mediante Machine Learning, continúa con el análisis de imágenes mediante Deep Learning y culmina con la comparación de arquitecturas de fusión híbridas.

El estudio evalúa mecanismos de integración multimodal tales como la fusión temprana, la fusión tardía y la Modulación Lineal de Características (FiLM), analizando su desempeño tanto bajo un enfoque de clasificación como de regresión. En el presente documento se detalla el análisis de los resultados experimentales obtenidos.

1.3 Modelos Unimodales

1.3.1 Datos Tabulares

El modelo base establecido mediante un **Random Forest Classifier** alcanzó un índice Quadratic Weighted Kappa (QWK) de **0.330**. El análisis de la matriz de confusión Figura 1.3 revela que el modelo presenta dificultades significativas para identificar la clase minoritaria Figura 1.2 (Clase 0: adopción el mismo día), debido al severo desbalanceo del conjunto de datos. Por el contrario, la Clase 4 (no adoptado en 100 días) es la que se predice con mayor precisión. Esto es coherente con la naturaleza del problema ya que es más sencillo discriminar binariamente si un animal será adoptado o no, que determinar con precisión el intervalo temporal específico (días vs. semanas) de dicha adopción.




Figura 1.2. Frecuencia de las distintas clases en nuestro conjunto de datos. Vemos como la clase cero se encuentra altamente desbalanceada

Adicionalmente, se experimentó con la incorporación de la descripción textual de las mascotas mediante técnicas de procesamiento de lenguaje natural (TF-IDF). Los resultados mostraron que esta variable no aporta ganancia de información significativa, obteniendo un QWK de 0.299, inferior al modelo tabular puro. La alta dimensionalidad y el ruido inherente al texto libre diluyen la capacidad predictiva de las variables estructuradas, por lo que se descartó su uso en las fases siguientes.




Figura 1.3. Matriz de confusión para RandomForest entrenado solo con datos tabulares

1.3.2 Imágenes

Para el análisis visual, se realizó un ajuste fino (*fine-tuning*) de una red **EfficientNetB0**. Este modelo unimodal obtuvo un QWK de **0.256**, un rendimiento inferior al de los datos tabulares. Sin embargo, el análisis detallado de su desempeño por clases arroja una observación clave: la red convolucional (CNN) demuestra una mayor sensibilidad en las clases intermedias (1 y 3) Figura 1.4, donde el Random Forest mostraba debilidades.

Aunque las imágenes por sí solas no constituyen el predictor dominante, su comportamiento complementario sugiere que la información visual captura matices que los datos tabulares no son capaces de clasificar, justificando la exploración de arquitecturas híbridas.




Figura 1.4. Matriz de confusión para EfficientNetB0 (CNN) entrenado solo con imagenes

1.4 Arquitecturas Multimodales: Enfoque de Clasificación

1.4.1 Fusión Temprana

Esta estrategia mostró un rendimiento deficiente, situándose en un QWK de **0.222**, por debajo incluso de la línea base tabular.

Esto es debido a que la concatenación directa de vectores visuales de alta dimensionalidad (maldición de la dimensionalidad) con las características tabulares parece haber introducido ruido en el modelo de Machine Learning clásico. Esto provoca un aumento drástico en el espacio de características con los embeddings de las imágenes, que poseen una varianza compleja, provocando que los árboles de decisión (Random Forest) pierdan eficiencia en la selección de los cortes óptimos diluyendo la capacidad predictiva que poseen los datos tabulares solos, empeorando la métrica a evaluar.

Se intentó mitigar este efecto mediante reducción de dimensionalidad con PCA (conservando el 80-90 % de la varianza), pero no se observaron mejoras significativas. Esto confirma que, para este problema, el modelo de fusión temprana para el enfoque de clasificación carece de sentido.




Figura 1.5. Esquema de la fusión temprana. Se extraen las características visuales de las imágenes con la CNN y se concatenan a los datos tabulares para posteriormente entrenar el Random Forest

1.4.2 Fusión Tardía

El enfoque de ensamblado (*Late Fusion*) resultó ser la estrategia más efectiva en clasificación, alcanzando un QWK de **0.365**.

Al entrenar las ramas tabular y visual de forma independiente y promediar sus predicciones probabilísticas *a posteriori*, se permite que cada modelo se especialice en su dominio sin interferencias. El análisis de optimización de pesos indicó que una combinación ponderada de 0,45 (CNN) y 0,55 (Random Forest) maximiza la estabilidad del modelo.

Este resultado valida que ambos modelos se complementan correctamente, los errores cometidos en el modelo tabular y en el visual no están fuertemente correlacionados permitiendo que una unión de ambos modelos supla los problemas del otro. Es decir, en muestras donde la imagen es

ambigua, los datos tabulares aportan certeza y viceversa, logrando una predicción conjunta más robusta que ambas por separado.

Arquitectura de Fusión Tardía (Ensamble)




Figura 1.6. Esquema de la fusión tardía. Se usan los dos modelos por separado y se ponderan sus probabilidades por un factor alpha

1.4.3 Modulación Lineal de Características (FiLM)

La arquitectura basada en FiLM Figura 1.7 obtuvo un QWK de **0.319**, superando a la CNN unimodal pero sin alcanzar el rendimiento del Random Forest puro o la fusión tardía.

El hecho de que FiLM mejore al modelo de solo imágenes demuestra la efectividad del mecanismo de atención: la red aprende a utilizar los datos tabulares para modular y focalizar la extracción de características visuales (por ejemplo, ponderando distintamente ciertas texturas según la edad del animal). Sin embargo, la arquitectura FiLM es intrínsecamente visual-céntrica, utilizando la tabla solo como un condicionante. Dado que en este dominio la información tabular posee un peso predictivo mayor (predictor dominante), una arquitectura que prioriza el flujo de procesamiento de imágenes parte con una desventaja estructural frente a los modelos basados principalmente en árboles de decisión.

Arquitectura de Modulación Lineal (FiLM) - Detallada




Figura 1.7. Esquema de la arquitectura FiLM. Se obtienen los mapas de características de las imágenes y se les aplica una transformación afín basada en datos tabulares

1.5 Arquitecturas Multimodales: Enfoque de Regresión

Para abordar el desafío de predicción de *AdoptionSpeed*, se optó por reformular el problema original de clasificación multiclase como un problema de regresión. Las etiquetas objetivo (0, 1, 2, 3, 4) poseen una relación ordinal intrínseca: una adopción muy rápida (0) es semánticamente más cercana a una rápida (1) que a una nula (4).

Los modelos de clasificación estándar tratan las clases como categorías independientes, penalizando de igual forma cualquier error. El enfoque de regresión, por el contrario, captura la magnitud del error, alineándose matemáticamente con la métrica de evaluación **Quadratic Weighted Kappa (QWK)**. Este cambio de paradigma permite al modelo aprender la continuidad subyacente de la adoptabilidad.

A continuación, se presenta el análisis de resultados de las tres estrategias bajo este paradigma.

1.5.1 Fusión Temprana (Regresión)

En la arquitectura de fusión temprana Figura 1.5 para regresión, se concatenaron las características visuales extraídas por EfficientNetB0 con las tabulares para entrenar un *Random Forest Regressor*. La predicción final se obtuvo mediante una media ponderada de las salidas continuas, seguida de una optimización de umbrales para discretizar los resultados. La optimización de los umbrales determina que hay ciertas clases que estarán menos representadas en la predicción del modelo, así como las clases 0,1 y 3. Sin embargo las clases 2 y 4 se verán muy representada y obtendrán una gran cantidad de aciertos, es decir la mayoría de datos etiquetados como clase 4 los acertará todo lo contrario pasará con las clases 0,1 y 3.

Los resultados (**QWK 0.261**) continuaron siendo inferiores a la línea base. Al igual que en clasificación, la introducción de un vector denso de características visuales en el regresor provoca que las variables visuales dominen la importancia de las características, oscureciendo la señal limpia de variables determinantes como la edad o la raza. El modelo no logra converger hacia una solución robusta debido a la complejidad del espacio de búsqueda.

A pesar de este desbalanceo ocurrido al optimizar los umbrales en el conjunto de validación, y

al resultado inferior a la base tabular Random Forest, la mejoría frente al modelo de clasificación supone un interés para analizar todas las arquitecturas vistas anteriormente, para comprobar si el enfoque de regresión es correcto para el dataset o solo en el caso de la fusión temprana.

1.5.2 Fusión Tardía (Regresión)

La estrategia de fusión tardía Figura 1.6 en regresión desacopló el entrenamiento de ambas modalidades, utilizando un *CNN Regressor* (EfficientNet con salida lineal) y un *Random Forest Regressor*. La predicción final se obtuvo mediante una media ponderada de las salidas continuas, seguida de una optimización de umbrales para discretizar los resultados, al igual que en el caso de fusión temprana.

Esta arquitectura obtuvo el mejor rendimiento global del proyecto, alcanzando un **QWK de 0.403**. La mejora sustancial respecto a la clasificación (0.365) y a la fusión temprana valida dos hipótesis fundamentales:

1. Procesar cada modalidad con su arquitectura nativa es más eficaz para preservar la integridad de la información.
2. El tratamiento de la variable objetivo como continua permite suavizar los errores de predicción.

La regresión visual captura la estética general, mientras que el modelo tabular ajusta la predicción basándose en factores logísticos. La combinación lineal de ambas señales continuas resulta en una estimación de la "velocidad de adopción".³ltamente correlacionada con la realidad.

1.5.3 Modulación Lineal de Características (FiLM - Regresión)

Finalmente, el modelo FiLM Figura 1.7 adaptado a regresión alcanzó un **QWK de 0.334**. Aunque superior a su contraparte de clasificación, sigue situándose por detrás de la fusión tardía.

Lo relevante de este resultado es la confirmación de la capacidad del mecanismo FiLM para integrar contexto. La inyección de pesos tabulares refina el análisis visual, permitiendo al modelo aprender a mirar la imagen condicionada por los datos. No obstante, al seguir dependiendo del flujo visual como eje central, no logra capitalizar completamente la potencia predictiva de los datos tabulares, que en este dataset específico actúan como la fuente primaria para una correcta predicción.

2 Discusión y Conclusiones

2.1 Discusión Crítica de las Estrategias de Fusión

Tras la evaluación experimental de las distintas arquitecturas multimodales, podemos extraer conclusiones válidas sobre el conjunto de datos *PetFinder*. Se observa como para este problema, el conjunto de datos tabulares aporta información más rica que la visual a la hora de predecir la duración de adopción. No obstante, se observa como ciertas arquitecturas híbridas logran aprovechar lo mejor de los dos mundos mejorando notablemente las métricas

2.1.1 Ineficacia de la Fusión Temprana: El Problema del Ruido Dimensional

La estrategia de **Fusión Temprana** (Early Fusion) demostró ser la aproximación menos efectiva, obteniendo resultados inferiores a los modelos unimodales base ($QWK \approx 0,22 - 0,26$).

Este bajo rendimiento se atribuye a la maldición de la dimensionalidad. Al concatenar directamente los vectores de características visuales (embeddings de 1280 dimensiones provenientes de EfficientNet) con las características tabulares procesadas, se introduce un nivel de ruido y varianza extremadamente alto en el espacio de entrada del regresor/clasificador final. El Random Forest, al intentar particionar este espacio híbrido, pierde la capacidad de identificar las variables determinantes (como la edad o la raza) entre la multitud de características visuales. Esto provoca que de esos resultados tan pobres.

2.1.2 FiLM: Potencial y Limitaciones

La arquitectura basada en **Modulación Lineal de Características (FiLM)** representó un avance técnico a la hora de trabajar con la CNN, logrando superar a la efficientNetB0 ($QWK \approx 0,33$).

El éxito relativo de FiLM reside en su mecanismo de atención condicionada: la red aprende coeficientes (γ, β) a partir de los metadatos para modular los mapas de características visuales. Esto demuestra que es posible enseñar a la red a mirar la imagen de manera diferente según el contexto tabular.

Sin embargo, su limitación es estructural. FiLM es una arquitectura *visión-céntrica*; utiliza la imagen como columna vertebral y la tabla como un mero condicionante. Dado que en este problema la información tabular es el predictor dominante, no logra alcanzar resultados extraordinarios.

2.1.3 Fusión Tardía: La Sinergia de Expertos Independientes

La **Fusión Tardía** (Late Fusion) se consolidó indiscutiblemente como la estrategia ganadora ($QWK = 0,403$). Su superioridad valida la hipótesis de la independencia de expertos.

Al desacoplar el entrenamiento, permitimos que cada modelo se especialice en su dominio sin interferencias: la CNN captura matices estéticos y emocionales, mientras que el Random Forest explota reglas lógicas sobre los metadatos. La mejora del rendimiento sugiere que los errores de ambos modelos están descorrelacionados; allí donde la imagen es ambigua, la información tabular aporta certeza, y viceversa. La combinación lineal final actúa como un mecanismo de reducción de varianza, suavizando las predicciones erróneas individuales.

2.2 El Impacto del Cambio de Paradigma: Clasificación vs. Regresión

Uno de los hallazgos más importantes de este proyecto es en el planteamiento matemático del problema. La transición de un enfoque de Clasificación Multiclase a uno de **Regresión Ordinal** supuso una mejora transversal en todas las métricas Figura 2.1.

Los modelos de clasificación estándar tratan las clases (0, 1, 2, 3, 4) como categorías independientes, penalizando de igual forma una confusión entre clases vecinas (ej. 0 y 1) que entre clases opuestas (ej. 0 y 4). Sin embargo, la velocidad de adopción posee una ordinalidad intrínseca.

El enfoque de regresión permite al modelo aprender la continuidad subyacente de la adoptabilidad y capturar la magnitud del error. Dado que la métrica de evaluación, **Quadratic Weighted**

Kappa (QWK), penaliza cuadráticamente las discrepancias lejanas, la función de pérdida de regresión (MSE) se alinea matemáticamente de forma mucho más natural con la métrica central del problema. Esto explica el salto de calidad observado en la Fusión Tardía, que pasó de un 0.365 (Clasificación) a un 0.403 (Regresión), un incremento relativo del 10.4 %.




Figura 2.1. Gráfica comparativa de las distintas arquitecturas híbridas en su versión clasificadora y regresiva. Observamos como la versión regresiva mejora de forma significativa todas las arquitecturas.

2.3 Conclusiones Generales

El presente trabajo permite extraer tres conclusiones fundamentales sobre la predicción multimodal en el dominio de adopción de mascotas:

1. **Dominancia Tabular:** Contrario a lo que se piensa de que una imagen vale más que mil palabras, en este dataset los metadatos estructurados (Edad, Raza, Salud, Coste) poseen un peso predictivo muy superior a la información visual. Cualquier arquitectura que diluya esta información (como la Fusión Temprana) o la subordine excesivamente (como modelos puramente de visión) tiende a dar malos resultados.
2. **Valor Incremental de la Multimodalidad:** A pesar de la dominancia tabular, la visión artificial no es redundante. La integración de ensamblados (como fusión tardía) aporta una mejora incremental crítica, permitiendo al sistema discriminar casos límite y detectar patrones estéticos que escapan a los datos tabulares.
3. **Arquitectura Óptima:** La configuración final recomendada es un sistema de **Fusión Tardía bajo un enfoque de Regresión** Tabla 2.1. Esta arquitectura, que combina un Random Forest Regresor y un EfficientNet Regresor mediante promedio ponderado y optimización de umbrales, alcanza el mejor resultado en nuestros experimentos (**QWK 0.403**), equilibrando la robustez estadística con la sensibilidad visual.

Tabla 2.1. Comparativa de resultados: Métricas QWK y coste computacional por modelo

Modelo / Arquitectura	QWK Score	Coste Computacional
Random Forest (Tabular)	0.330	Bajo
CNN EfficientNetB0 (Imagen)	0.256	Alto
Fusión Temprana (Clasificación)	0.222	Bajo-Medio
Fusión Tardía (Clasificación)	0.365	Alta
FiLM (Clasificación)	0.319	Alto
Fusión Temprana (Regresión)	0.261	Medio-Alta
Fusión Tardía (Regresión)	0.403	Alta
FiLM (Regresión)	0.334	Medio-Alto

3 Anexo: Aprendizajes de la asignatura

3.1 Aprendizajes clave del trabajo

Este trabajo nos ha servido para entender que en el mundo real no siempre gana el modelo más complejo, sino el que mejor entiende los datos que tiene. Al trabajar con PetFinder, nos dimos cuenta de que la fuerza de la predicción estaba sobre todo en los datos de la tabla (como la edad o la raza) y no tanto en las fotos. Aprendimos que un Random Forest puede ser más fiable que una red neuronal profunda si los datos estructurados son buenos. Esto nos enseñó una lección importante: antes de lanzarse a usar Deep Learning para todo, hay que analizar qué parte de la información es la que realmente aporta.

Al intentar mezclar las dos fuentes de datos (imágenes y tablas), vimos que no vale con usar cualquier arquitectura. Con la fusión temprana aprendimos que si metes un vector de imagen enorme junto a unos pocos datos de una tabla, el modelo no logra generalizar con tanto ruido y deja de ver lo que era importante. Por eso, la fusión tardía nos funcionó mucho mejor. Aprendimos que para este problema donde los datos tabulares son clave, es más inteligente dejar que cada modelo sea un experto en su tema por separado y juntar sus opiniones al final. También probamos FiLM, que nos pareció muy interesante porque permite que la tabla le de instrucciones a la red neuronal sobre en qué fijarse de la foto a partir de los datos tabulares.

Uno de los mayores descubrimientos fue el cambio de clasificación a regresión. Aprendimos que si las clases tienen un orden (como en la velocidad de adopción, donde 0 es más cerca de 1 que de 4), no tiene sentido tratarlas como si no tuvieran relación. Al usar regresión, el modelo entiende la distancia de sus errores, lo que hizo que nuestra métrica (el QWK) subiera de golpe. Además, vimos que el trabajo no acaba al entrenar el modelo: tuvimos que aprender a optimizar los umbrales de corte a mano, porque los que vienen por defecto no siempre son los mejores para repartir las predicciones. En general, este proyecto nos ha enseñado a diseñar sistemas híbridos, a saber cuándo una imagen ayuda y cuándo estorba, y a ajustar matemáticamente el modelo para que responda exactamente a lo que pide el problema.

3.2 Aprendizajes adquiridos en la asignatura de Deep Learning

La asignatura de Deep Learning ha permitido adquirir una comprensión sólida de los fundamentos teóricos y prácticos del aprendizaje profundo, así como de las principales arquitecturas

empleadas en problemas reales de predicción y clasificación. A lo largo del curso se han trabajado redes totalmente conectadas, convolucionales y recurrentes, junto con técnicas de optimización y regularización, lo que ha facilitado entender cómo las decisiones de diseño y entrenamiento influyen en el comportamiento y el rendimiento de los modelos.

Un aspecto especialmente relevante del aprendizaje ha sido el uso de *cuadernillos jupyter interactivos*, que han permitido analizar de forma visual el funcionamiento interno de las redes neuronales, que con un libro difícilmente se puede lograr. Mediante estos ejercicios prácticos ha sido posible observar cómo actúan los distintos parámetros que componen los modelos, como los pesos, las funciones de activación, las funciones de pérdida y los algoritmos de optimización, y cómo su ajuste afecta al proceso de entrenamiento y a la capacidad de generalización. Esto ha contribuido a consolidar los conceptos teóricos y a desarrollar una comprensión más profunda del funcionamiento interno de los modelos de Deep Learning, que muchas veces se ven como una caja negra.

3.3 Aprendizajes adquiridos en la asignatura de Machine Learning

La asignatura de Machine Learning ha permitido adquirir una base sólida sobre los principios fundamentales del aprendizaje automático, abordando tanto técnicas de aprendizaje supervisado como no supervisado. A lo largo del curso se han estudiado y aplicado algoritmos clásicos como regresión lineal y logística, k-nearest neighbours y árboles de decisión. Este recorrido ha facilitado comprender el alcance y las limitaciones, así como la importancia de una evaluación rigurosa mediante métricas y procedimientos de validación adecuados. También se ha desarrollado la capacidad de análisis de los resultados obtenidos por los modelos predictivos.

Un aspecto especialmente relevante de la metodología empleada en la asignatura ha sido la resolución de problemas de forma manual. Este enfoque ha permitido analizar con detalle qué ocurre en el interior de los modelos y algoritmos. La resolución paso a paso de estos problemas permite interiorizar conceptos clave como el ajuste de modelos, la toma de decisiones en clasificación y regresión, y el efecto de los hiperparámetros sobre el rendimiento. De este modo, el aprendizaje no se ha limitado a la aplicación directa de las librerías clásicas de Machine Learning, sino que ha favorecido una comprensión profunda del funcionamiento interno de los algoritmos de Machine Learning, evitando tratarlos como cajas negras.